

Correction TD1

+

Suite du cours

Anagrammes

- Autre exemple: à partir d'une liste de mots, on cherche à déterminer lesquels sont des anagrammes.
- Données d'entrée:

```
crane  
imaginer  
surface  
metropole  
migraine  
structure  
ancre
```

- Là aussi, le choix de la clef est crucial.

Anagrammes

- *map*: renvoie un couple (clef;valeur), avec le mot pour valeur et les lettres du mot ordonnées dans l'ordre alphabétique pour clef.
- La clef constitue de fait un « point commun » aux anagrammes: les lettres elles-même, ordonnées. Le *shuffle* devrait donc regrouper les anagrammes ensemble.
- Après execution:

```
("acenr";"crane")  
("aegiimnr";"imaginer")  
("acefrsu";"surface")  
("eelmooprt";"metropole")  
("aegiimnr";"migraine")  
("cerrsttuu";"structure")  
("acenr";"ancre")
```

Anagrammes

- Après l'étape de *shuffle*:

```
("acenr";"crane"), ("acenr";"ancre")
```

```
("aegiimnr";"imaginer"), ("aegiimnr";"migraine")
```

```
("acefrsu";"surface")
```

```
("eelmooprt";"metropole")
```

```
("cerrsttuu";"structure")
```

Anagrammes

- *reduce*: concatène toutes les valeurs d'entrée pour la clef unique; renvoie un couple (clef;valeur) avec la clef d'entrée pour clef et la chaîne ainsi concaténée pour valeur.
- Après execution:

```
("acenr";"crane ancre")  
("aegiimnr";"imaginer migraine")  
("acefrsu";"surface")  
("eelmooprt";"metropole")  
("cerrsttuu";"structure")
```

Sentiment Client/Twitter

- Clef: un descripteur de sentiment client (« satisfait », « insatisfait » ou « attente », « inconcluant »).
- *map*: génère un couple (clef;valeur) par sentiment client détecté (mot correspondant à une liste prédéfinie).
- Si deux sentiments contradictoires détectés: renvoyer inconcluant.
- On renvoie un couple (clef;valeur) pour chaque fragment des données d'entrée: chaque *tweet*

Sentiment Client/Twitter

Pseudo code:

```
WORDS_BAD = ["nul", "insatisfait", "bof", "incompétents", ...]
WORDS_GOOD = ["satisfait", "super", "excellent", ...]
BAD=0; GOOD=0
POUR MOT dans [TWEET], FAIRE:
  SI MOT PRESENT_DANS WORDS_BAD:
    BAD=1
  SINON SI MOT PRESENT_DANS WORDS_GOOD:
    GOOD=1
SI BAD==1 ET GOOD==0:
  RENVOYER("insatisfait",1)
SINON SI BAD==0 ET GOOD=1:
  RENVOYER("satisfait",1)
SINON:
  RENVOYER("inconcluant",1)
```

Sentiment Client/Twitter

• Après exécution:

```
"@acme Votre service client est nul"
"@acme 30min d'attente... très insatisfait"
"Très satisfait par un produit super !! @acme"
"merci d'avoir RT @acme"
"@acme produit déjà cassé, super insatisfait !"
```



```
("insatisfait";1)
("insatisfait";1)
("satisfait";1)
("inconcluant";1)
("inconcluant";1)
```

Sentiment Client/Twitter

- *reduce*: additionne les valeurs associées à la clef unique; renvoie le total pour valeur (identique au *reducer* du compteur d'occurrences de mots).

- Après exécution:

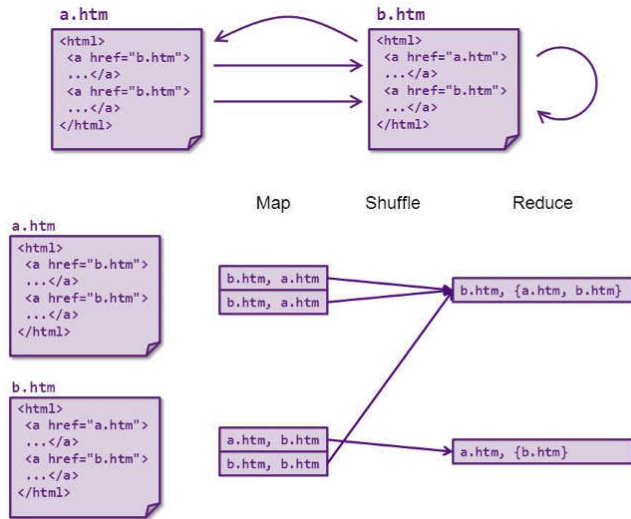
```
("insatisfait";2)  
("satisfait";1)  
("inconcluant";2)
```

- Conclusion: lors de la dernière heure, 33% de *tweets* exprimant de la satisfaction.
- En important, heure par heure, les données au sein d'une base de données relationnelle, on pourra obtenir en permanence des statistiques sur la satisfaction à partir de *twitter*.

Liens Web inverses

- Soit un très grand ensemble de pages web
- Pour chaque page p dans l'ensemble
 - Trouver l'ensemble des pages qui référencent p
- Ex. si dans les pages p_1 et p_2 , il y a des liens vers la page q , alors nous avons:
 - Sources(q) : $\{p_1, p_2, \dots\}$

Liens Web inverses



Liens Web inverses

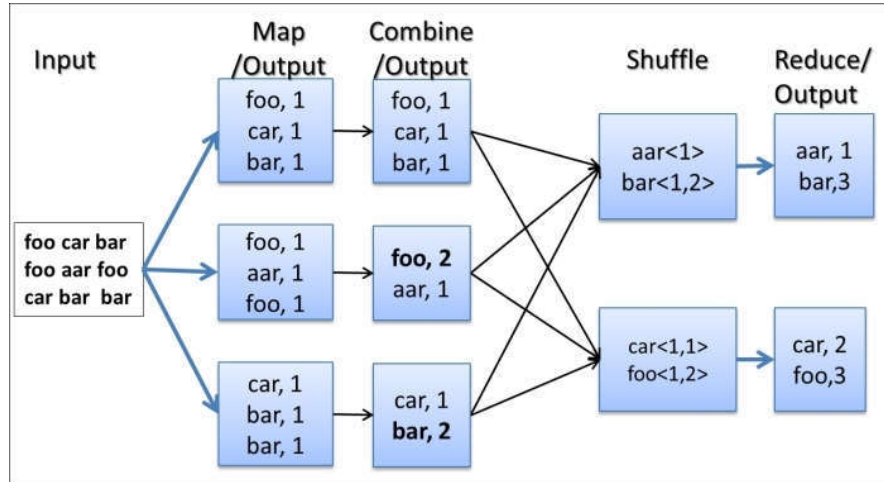
- Map
 - For each URL linking to target, ...
 - Output <target, source> pairs
- Reduce
 - Concatenate list of all source URLs
 - Outputs: <target, **list** (source)> pairs

Liens Web inverses

```
map(key, value):  
  // key: un URL de page web; value: contenu de la page  
  // p: the given pattern  
  for each link to a target t in value  
    EmitIntermediate (t, {key});  
  
reduce(key, values):  
  // key: un URL; values: une liste d'URLs référçant key  
  src_set = {};  
  for each value v in values  
    if v  $\notin$  src_set then  
      src_set = src_set + v;  
  Emit(key, src_set);
```

Suite du cours

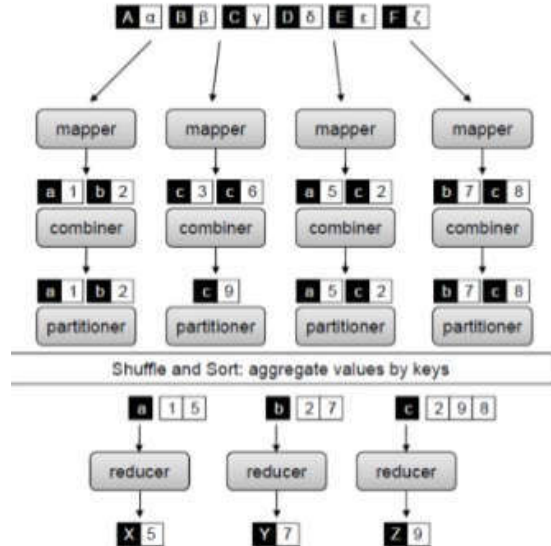
Amélioration de WorCount: Utilisation du Combiner



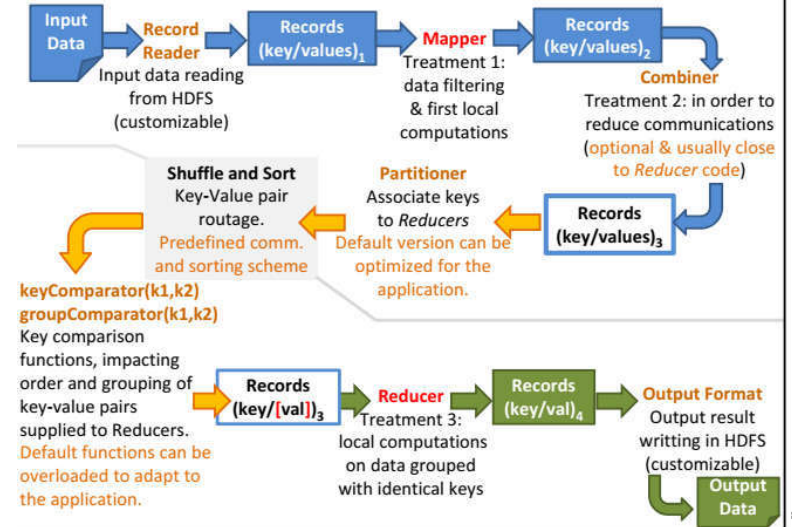
Amélioration de WorCount: Utilisation du Combiner

Without Combiner				With Combiner			
Map input records	0	0	4,138,476	Map input records	0	0	4,138,476
Map output records	0	0	4,138,476	Map output records	0	0	4,138,476
Map output bytes	0	0	67,381,890	Map output bytes	0	0	67,381,890
Input split bytes	0	0	820	Input split bytes	0	0	820
Combine input records	0	0	0	Combine input records	0	0	4,140,333
Combine output records	0	0	0	Combine output records	0	0	2,266
Reduce input groups	0	0	103	Reduce input groups	0	0	103
Reduce shuffle bytes	0	0	75,658,866	Reduce shuffle bytes	0	0	9,609
Reduce input records	0	0	4,138,476	Reduce input records	0	0	412
Reduce output records	0	0	103	Reduce output records	0	0	103
Spilled Records	0	0	12,219,835	Spilled Records	0	0	2,678
CPU time spent (ms)	0	0	43,420	CPU time spent (ms)	0	0	31,420
Physical memory (bytes) snapshot	0	0	463,062,000	Physical memory (bytes) snapshot	0	0	1,944,132,556
Virtual memory (bytes) snapshot	0	0	1,941,934,080	Virtual memory (bytes) snapshot	0	0	1,944,887,296
Total committed heap usage (bytes)	0	0	772,935,680	Total committed heap usage (bytes)	0	0	657,997,824
BYTES_READ	211,312,924	0	211,312,924	BYTES_READ	211,312,924	0	211,312,924

Résumé: Chaîne d'opérations MAP/REDUCE



Résumé: Chaîne d'opérations MAP/REDUCE



Résumé: Chaîne d'opérations MAP/REDUCE

- En entrée de la chaîne se trouve une classe de lecture des données, appelée *Record Reader*).

Cette classe lit le fichier HDFS d'entrée et le convertit en paires clé-valeur que traitera la fonction *map*. Par défaut elle lit ligne par ligne un flux d'entrée sensé être un fichier texte, et crée une paire dont la clé est l'offset (en octets) de cette ligne dans le fichier et dont la valeur est la ligne elle-même. L'ensemble du *Record Reader* est redéfinissable par l'utilisateur, ainsi que le type des données d'entrée (qui pourraient ne pas être du texte ASCII).

Résumé: Chaîne d'opérations MAP/REDUCE

- La classe *Combiner* est un *Reducer* local et optionnel. Cette classe applique un traitement aux paires de sortie de la fonction *map* pour les combiner. En général elle fait la même chose ou presque que la classe *Reducer* sur un ensemble de paires de même clé, et permet de réduire le volume de données routées ensuite vers les *Reducer*. Sa définition n'est pas obligatoire, et si cette classe est définie, alors *Hadoop* décide librement à quels moments l'appeler pour combiner les sorties de chaque *Mapper*. L'utilisation d'un *Combiner* permet d'améliorer les performances en réduisant le trafic lors du *Shuffle & Sort*, mais entraîne quelques contraintes algorithmiques.

Résumé: Chaine d'opérations MAP/REDUCE

- Le *Partitioner* est une classe optionnelle qui permet de spécialiser la répartition des clés sur les différents *Reducer*. Toutes les paires de même clé sont envoyées à un même *Reducer*, mais un *Reducer* peut gérer plusieurs clés. Par défaut, *Hadoop* effectue une répartition aléatoire grossière des clés sur les *Reducer*. Il est possible de définir une politique de répartition de charge plus équilibrée si on a connaissance des clés possibles et de la distribution des volumes de valeurs associés.

Résumé: Chaine d'opérations MAP/REDUCE

- L'étape de *shuffle & sort* n'est pas redéfinissable. Le schéma de communication est imposé et ressemble à un *all-to-all* orienté des *Mappers* vers les *Reducers* (pour emprunter le vocabulaire du HPC). Cependant, la stratégie de redistribution des clés vers les *Reducers* peut être redéfinie par le *Partitioner* présenté précédemment, ainsi que la stratégie de tri des clés et de regroupement des valeurs en entrée de chaque *Reducer* (voir ci-après).

Résumé: Chaîne d'opérations MAP/REDUCE

- Deux fonctions de comparaison de clés à l'entrée des *Reducers* (*keyComparator* et *group-Comparator*) permettent de contrôler l'ordre dans lequel les paires *clé - listes de valeurs* seront constituées et présentées aux *Reducers* (ce qui permet d'optimiser fortement certains algorithmes).
- Enfin, le format de sortie peut-être modifié dans l'interface *OutputFormat*, qui définit quels types de clés et valeurs de sortie sont attendues et comment les écrire sur disque. Par défaut, n'importe quel types de données *Writable* peut être écrit dans un fichier texte, et les paires de sortie des *Reducer* sont bien celles écrites sur disques.

La chaîne *Map-Reduce* d'*Hadoop* est donc optimisable ou spécialisable à plusieurs niveaux, mais fonctionne avec des comportements par défaut à toutes les étapes.



- Un *Mapper* par bloc de fichier d'entrée (beaucoup de *Mappers*)
- Un *Combiner* associé à chaque *Mapper* pour réduire le trafic dans le *Shuffle & Sort*
- Quelques *Reducers*, fonctions du nombre de termes attendus
- Un *Partitioner* pour améliorer l'équilibrage de charge entre *Reducers* ... ssi connaissances pertinentes sur les résultats attendus!

Complément Hadoop MapReduce

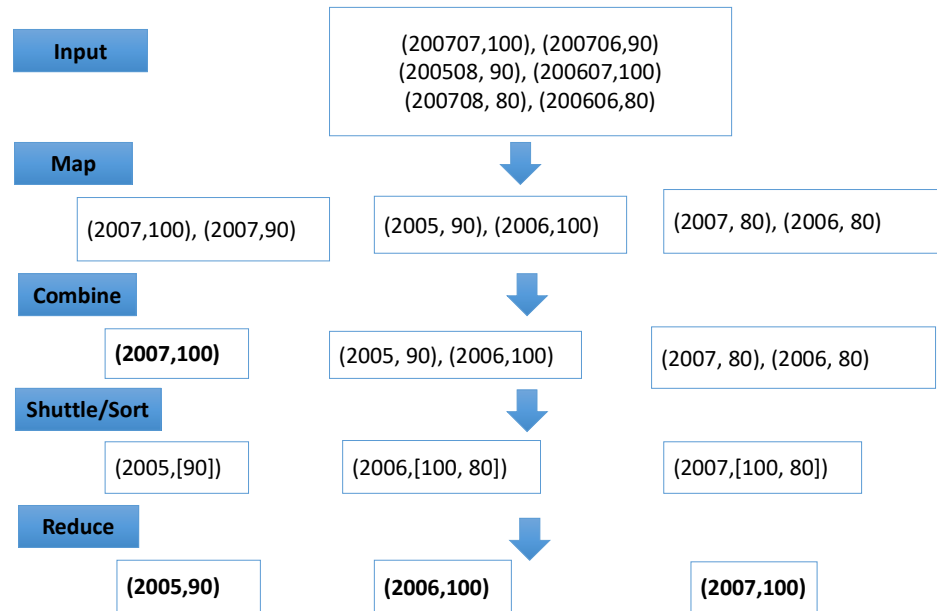
Exercices: Max, moyenne, Combiners

- **Exercice 1 : Calcul de la température maximale**
- On souhaite calculer la température mensuelle maximale pour chaque année à partir des bulletins météorologiques.
- Données en entrée : enregistrement de la forme :
- <Year/Month, Average Temperature of that month>
- - (200707,100), (200706,90)
- - (200508, 90), (200607,100)
- - (200708, 80), (200606,80)
- On suppose que les données sont découpées par ligne.
- Donner les fonctions MAP et Reduce
-

Mapper and Reducer of Max Temperature

- **Map(key, value){**
 // key: line number
 // value: tuples in a line
 for each tuple t in value:
 Emit(t->year, t->temperature);
Combiner is the same as Reducer
- **Reduce(key, list of values){**
 // key: year
 //list of values: a list of monthly temperature
 int max_temp = -100;
 for each v in values:
 max_temp= max(v, max_temp);
 Emit(key, max_temp);}

MapReduce Example: Max Temperature



MapReduce In-class Exercise

- **Key-Value Pair of Map and Reduce:**

- **Map:** (year, temperature)
- **Reduce:** (year, maximum temperature of the year)

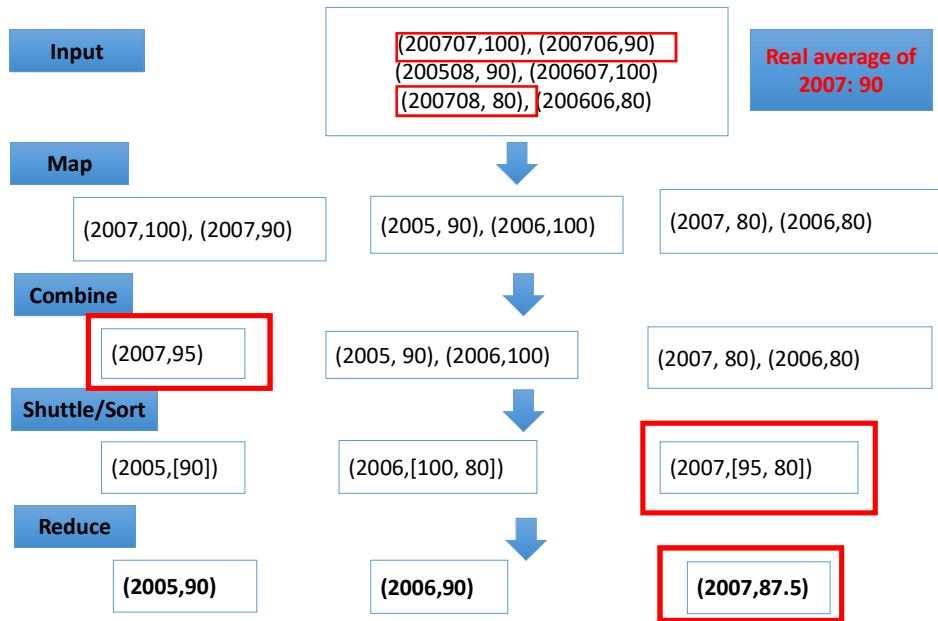
- **Question: How to use the above Map Reduce program (*that contains the combiner*) with slight changes to find the average monthly temperature of the year?**

Mapper and Reducer of Average Temperature

```
• Map(key, value){  
    // key: line number  
    // value: tuples in a line  
    for each tuple t in value:  
        Emit(t->year, t->temperature);}  
  
• Reduce(key, list of values){  
    // key: year  
    // list of values: a list of monthly temperatures  
    int total_temp = 0;  
    for each v in values:  
        total_temp= total_temp+v;  
    Emit(key, total_temp/size_of(values));}
```

Combiner is the same as Reducer

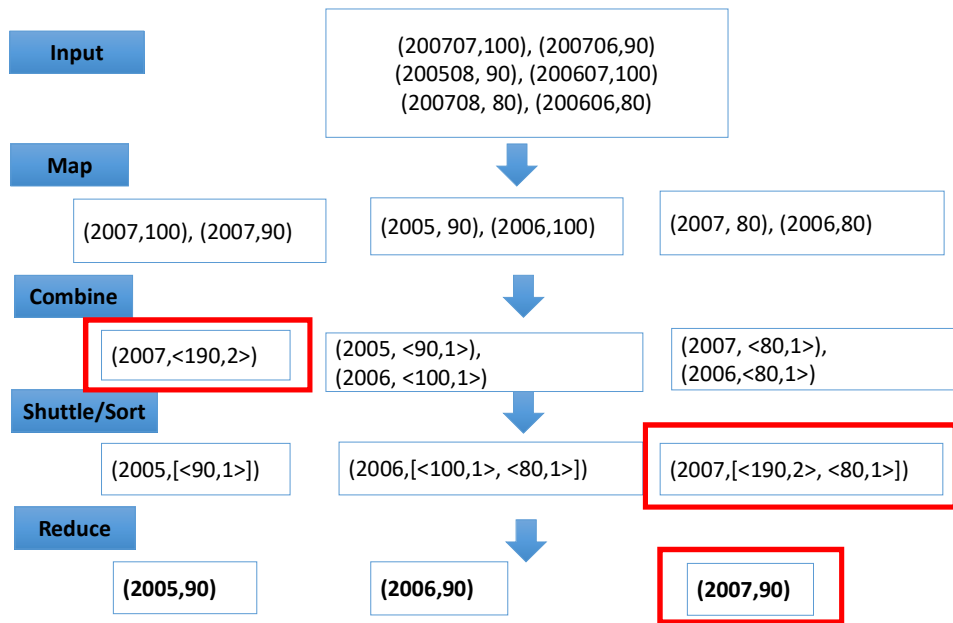
MapReduce Example: Average Temperature



MapReduce In-class Exercise

- **The problem is with the combiner!**
- **Here is a simple counterexample:**
 - `(2007, 100), (2007,90) -> (2007, 95)`
`(2007,80)->(2007,80)`
 - Average of the above is: `(2007,87.5)`
 - However, the real average is: `(2007,90)`
- **However, we can do a small trick to get around this**
 - Mapper: `(2007, 100), (2007,90) -> (2007, <190,2>)`
`(2007,80)->(2007,<80,1>)`
 - Reducer: `(2007,<270,3>)->(2007,90)`

MapReduce Example: Average Temperature



Mapper and Reducer of Average Temperature

- **Map(key, value){**
 // key: line number
 // value: tuples in a line
 for each tuple t in value:
 Emit(t->year, t->temperature);
}
- **Combine(key, list of values){**
 // key: year
 // list of values: a list of monthly temperature
 int total_temp = 0;
 for each v in values:
 total_temp= total_temp+v;
 Emit(key,<total_temp,size_of(values)>);}
- **Reduce (key, list of values){**
 // key: year
 // list of values: a list of <temperature sums, counts> tuples
 int total_temp = 0;
 int total_count=0;
 for each v in values:
 total_temp= total_temp+v->sum;
 total_count=total_count+v->count;
 Emit(key,total_temp/total_count);}

MapReduce In-class Exercise

- **Functions that can use combiner are called *distributive*:**

- Distributive: Min/Max(), Sum(), Count(), TopK()
- Non-distributive: Mean(), Median(), Rank()


Gray, Jim*, et al. "Data cube: A relational aggregation operator generalizing group-by, cross-tab, and sub-totals." Data Mining and Knowledge Discovery 1.1 (1997): 29-53.

*Jim Gray received Turing Award in 1998

Map Reduce Problems Discussion

- **Problem 1:** Find Word Length Distribution
- **Statement:** Given a set of documents, use Map-Reduce to find the length distribution of all words contained in the documents
- **Question:**
 - What are the Mapper and Reducer Functions?

MapReduce



Mapper and Reducer of Word Length Distribution

- **Map(key, value){**
 - // key: document name
 - // value: words in a document
 - for each word w in value:
 - Emit(length(w), w);}**
- **Reduce(key, list of values){**
 - // key: length of a word
 - // list of values: a list of words with the same length
 - Emit(key, size_of(values));}**

Map Reduce Problems Discussion

- **Problem 1:** Find Word Length Distribution
- **Mapper and Reducer:**
 - Mapper(document)
 - { **Emit (Length(word), word) }**
 - Reducer(output of map)
 - { **Emit (Length(word), Size of (List of words at a particular length))**}

Patron de calcul d'une moyenne

