

Chapitre : Evaluation de l'apprentissage

Plan

1. Introduction
2. Matrice de confusion
3. Courbe ROC
4. Erreurs de régression
5. Généralisation et sur-apprentissage

Introduction

- Questions types:
 - Quelle est la performance d'un système sur un type de tâche ?
 - Est-ce que mon système est meilleur que l'autre ?
 - Comment dois-je régler mon système ?

Introduction

Types de mesures de performance

Il existe de nombreuses façons d'évaluer la performance prédictive d'un modèle d'apprentissage supervisé. les principaux critères utilisés

Correctly Classified Instances	117	70.9091 %
Incorrectly Classified Instances	48	29.0909 %
Kappa statistic	0.3071	
Mean absolute error	0.2909	
Root mean squared error	0.5394	
Relative absolute error	62.6804 %	
Root relative squared error	112.1168 %	
Total Number of Instances	165	

SVM

==== Detailed Accuracy By Class ====

TP Rate	FP Rate	Precision	Recall	F-Measure	ROC Area	Class
0.895	0.617	0.718	0.895	0.797	0.639	good
0.383	0.105	0.676	0.383	0.489	0.639	bad
Weighted Avg.	0.709	0.431	0.703	0.709	0.639	

==== Confusion Matrix ====

a	b	<-- classified as
94	11	a = good
37	23	b = bad

Correctly Classified Instances	103	62.4242 %
Incorrectly Classified Instances	62	37.5758 %
Kappa statistic	0.1995	
Mean absolute error	0.3793	
Root mean squared error	0.5316	
Relative absolute error	81.7353 %	
Root relative squared error	110.5048 %	
Total Number of Instances	165	

Naive Bayes

==== Detailed Accuracy By Class ====

TP Rate	FP Rate	Precision	Recall	F-Measure	ROC Area	Class
0.686	0.483	0.713	0.686	0.699	0.674	good
0.517	0.314	0.484	0.517	0.5	0.674	bad
Weighted Avg.	0.624	0.422	0.63	0.624	0.627	0.674

==== Confusion Matrix ====

a	b	<-- classified as
72	33	a = good
29	31	b = bad

Introduction

Types de mesures de performance

- Test set: 105 good, 60 bad
 - NB Accuracy 62.4%
 - SVM Accuracy 70.1%

SVM

Classified as

good	bad		
94	11	good	Act.
37	23	bad	Class

Naive Bayes

Classified as

good	bad		
72	33	good	Act.
29	31	bad	Class



Introduction

Types de mesures de performance

- Test set: 105 good, 60 bad
 - NB Accuracy 62.4%
 - SVM Accuracy 70.1%

SVM

Classified as		Act.	Class
good	bad		
94	11	good	
37	23	bad	

SVM biased toward majority class

Naive Bayes

Classified as		Act.	Class
good	bad		
72	33	good	
29	31	bad	

What if this is important?

Introduction

Types de mesures de performance

```
==== Detailed Accuracy By Class ====

      TP Rate    FP Rate    Precision    Recall    F-Measure    ROC Area    Class
          0.895       0.617       0.718       0.895       0.797       0.639    good
          0.383       0.105       0.676       0.383       0.489       0.639    bad
Weighted Avg.      0.709       0.431       0.703       0.709       0.685       0.639

==== Confusion Matrix ====

  a   b   <-- classified as
94 11 |   a = good
37 23 |   b = bad
```



Matrice de confusion

- Étant donné un problème de classification, on appelle matrice de confusion une matrice \mathbf{M} contenant autant de lignes que de colonnes que de classes, et dont l'entrée M_{ck} est le nombre d'exemples de la classe **c** pour laquelle l'étiquette **k** a été prédite

<i>réel</i>	<i>Estimé</i>		
	+	-	
+	<i>VP</i>	<i>FN</i>	
-	<i>FP</i>	<i>VN</i>	

Matrice de confusion

		Estimé	
		+	-
<i>Réel</i>	+		
	+	<i>VP</i>	<i>FN</i>
-	-	<i>FP</i>	<i>VN</i>

- **VP:** vrais positifs (true positives) les exemples positifs correctement classifiés
- **FP:** faux positifs (false positives) les exemples négatifs étiquetés positifs par le modèle ;
- et réciproquement pour les **vrais négatifs VN** (true negatives) et les **faux négatifs FN** (false negatives).
- On note généralement par **TP** le nombre de vrais positifs, **FP** le nombre de faux positifs, **TN** le nombre de vrais négatifs et **FN** le nombre de faux négatifs.
- ▶ ■ Les faux positifs sont aussi appelés **fausses alarmes**.

Matrice de confusion

Il est possible de dériver de nombreux critères d'évaluation à partir de la matrice de confusion.

- On appelle **rappel** (recall), ou **sensibilité** (sensitivity), le taux de vrais positifs, c'est-à-dire la proportion d'exemples positifs correctement identifiés.

*Rappel ou
Sensibilité*

$$\frac{VP}{VP + FN}$$

		Estimé		
Réel		+	-	
+	+	VP		FN
	-	FP	VN	

- Il est cependant très facile d'avoir un bon **rappel** en prédisant que tous les exemples sont positifs.
- Ainsi, ce critère ne peut pas être utilisé seul. On lui adjoint ainsi souvent la **précision**.



Matrice de confusion--Indicateurs de performances

- On appelle **précision**, ou valeur positive prédictive (positive predictive value, PPV) la proportion de prédictions correctes parmi les prédictions positives :

$$\text{Précision} = \frac{VP}{VP + FP}$$

		Estimé	
		Réel	
		+	-
+	Réel	VP	
			FN
-	Estimé		VN
		FP	

- On appelle **spécificité** le taux de vrais négatifs, autrement dit la proportion d'exemples négatifs correctement identifiés comme tels.

$$\text{Spécificité} = \frac{VN}{VN + FP}$$

Matrice de confusion--Indicateurs de performances

- ▶ Pour résumer rappel et précision en un seul nombre, on calculera la F-mesure (F-score ou F1-score), c'est la moyenne harmonique de la précision et du rappel:

F-measure

$$\frac{2 \times \text{rappel} \times \text{précision}}{\text{rappel} + \text{précision}} = \frac{2 VP}{2 VP + FP + FN}$$

Autres mesures:

FN-rate

$$\frac{FN}{VP + FN}$$

FN Rate « false negatif » : nombre de fois que la classe non prédict par le classifieur correspond à la vraie classe

FP-rate

$$\frac{FP}{FP + VN}$$

FP Rate « false positive » : nombre de fois que la classe prédict par le classifieur ne correspond pas à la vraie classe.

Exemples de MC

Actual condition	Predicted condition	
	Cancer	Non-cancer
Total $8 + 4 = 12$		
Cancer	6	2
Non-cancer	1	3

Confusion Matrix for binary Classification

	Apple	Orange	Mango
Apple	7	8	9
Orange	1	2	3
Mango	3	2	1

Confusion Matrix for Multi-Class Classification

Évaluation de méthodes de classification binaire retournant un score

- ▶ Si les algorithmes de classification ne retournent pas directement une étiquette de classe,
 - utilisent **une fonction de décision** qui doit ensuite être seuillée pour devenir une étiquette.
- ▶ Cette fonction de décision peut être un score arbitraire
 - par exemple, la proportion d'exemples positifs parmi les **k** plus proches voisins du point à étiqueter
 - ou la probabilité d'appartenir à la classe positive
- ▶ Plusieurs critères permettent d'évaluer la qualité de la fonction de décision avant seuillage.(exp: Courbe ROC)


Courbe ROC

ROC (Receiver-Operator Characteristic)

- ▶ Le terme vient des télécommunications, où ces courbes servent à étudier si un système arrive à séparer le signal du bruit de fond.
- ▶ Décrire l'évolution de la sensibilité (TVP) en fonction du complémentaire à 1 de la spécificité, (1 - spécificité ou TFP)
 - ▶ $TVP = \text{Rappel} = \text{Sensibilité} = VP/\text{Positifs}$
 - ▶ $TFP = 1 - \text{Spécificité} = FP/\text{Négatifs}$
- ▶ L'idée de la courbe ROC est de faire varier le « seuil » de 1 à 0 et, pour chaque cas, calculer le TVP et le TFP que l'on reporte dans un graphique

Courbe ROC

Le *point(0, 0)* apparaît quand on utilise comme seuil un nombre supérieur à la plus grande valeur rentrée par la fonction de décision :
→ tous les exemples sont étiquetés négatifs.



Les courbes ROC de deux modèles

Courbe ROC

Construction de la courbe ROC (1/2)

Classer les données
selon un score décroissant

Individu	Score (+)	Classe
1	1	+
2	0.95	+
3	0.9	+
4	0.85	-
5	0.8	+
6	0.75	-
7	0.7	-
8	0.65	+
9	0.6	-
10	0.55	-
11	0.5	-
12	0.45	+
13	0.4	-
14	0.35	-
15	0.3	-
16	0.25	-
17	0.2	-
18	0.15	-
19	0.1	-
20	0.05	-

Positifs = 6
Négatifs = 14

Seuil = 1

	^positif	^négatif	Total
positif	1	5	6
négatif	0	14	14
Total	1	19	20

Taux de vrais positifs Taux des Vrais Négatifs

$$TVP = 1/6 = 0.2 ; TFP = 0/14 = 0$$

Seuil = 0.95

	^positif	^négatif	Total
positif	2	4	6
négatif	0	14	14
Total	2	18	20

$$TVP = 2/6 = 0.33 ; TFP = 0/14 = 0$$

Seuil = 0.9

	^positif	^négatif	Total
positif	3	3	6
négatif	0	14	14
Total	3	17	20

$$TVP = 3/6 = 0.5 ; TFP = 0/14 = 0$$

Seuil = 0.85

	^positif	^négatif	Total
positif	3	3	6
négatif	1	13	14
Total	4	16	20

$$TVP = 3/6 = 0.5 ; TFP = 1/14 = 0.07$$

Seuil = 0

	^positif	^négatif	Total
positif	6	0	6
négatif	14	0	14
Total	20	0	20

$$TVP = 6/6 = 1 ; TFP = 14/14 = 1$$

Courbe ROC

Construction de la courbe ROC (2/2)

Mettre en relation

TFP (abscisse) et TVP (ordonnée)

Individu	Score (+)	Classe	TFP	TVP
1	1	+	0.000	0.167
2	0.95	+	0.000	0.333
3	0.9	+	0.000	0.500
4	0.85	-	0.071	0.500
5	0.8	+	0.071	0.667
6	0.75	-	0.143	0.667
7	0.7	-	0.214	0.667
8	0.65	+	0.214	0.833
9	0.6	-	0.286	0.833
10	0.55	-	0.357	0.833
11	0.5	-	0.429	0.833
12	0.45	+	0.429	1.000
13	0.4	-	0.500	1.000
14	0.35	-	0.571	1.000
15	0.3	-	0.643	1.000
16	0.25	-	0.714	1.000
17	0.2	-	0.786	1.000
18	0.15	-	0.857	1.000
19	0.1	-	0.929	1.000
20	0.05	-	1.000	1.000




Calcul pratique

TFP (i) = Nombre de négatifs parmi les « i » premiers / (nombre total des négatifs)

TVP (i) = Nombre de positifs parmi les « i » premiers / (nombre total des positifs)


Courbe ROC



Courbe ROC et AUC

- ▶ L'aire sous la courbe (ou *Area Under the Curve – AUC*) est un indice synthétique calculé pour les courbes ROC.
- ▶ **L'AUC** correspond à la probabilité pour qu'un événement positif soit classé comme positif par le test sur l'étendue des valeurs seuil possibles.
- ▶ AUC est utilisé pour comparer les modèles !

Courbe ROC et AUC




- ▶ Pour un modèle idéal, $AUC=1$,
- ▶ pour un modèle aléatoire, $AUC=0.5$;
(Symbolisée par la diagonale principale dans le graphique)

- ▶ Habituellement le modèle est bon dès lors que la valeur de l'AUC est supérieure à 0.7.
 - ▶ Un modèle bien discriminant doit avoir une AUC entre 0.87 et 0.9.
 - ▶ Un modèle ayant une AUC supérieure à 0.9 est excellent.

Courbe ROC--Interprétation : dominance

Question: Comment montrer que M1 sera toujours meilleur que M2, quelle que soit la matrice de coût de mauvaise affectation utilisée ?




Interprétation : La courbe de M1 est toujours « au-dessus » de celle de M2 : il ne peut pas exister de situation (matrice de coût de mauvais classement) où M2 serait un meilleur modèle de prédiction

Courbe ROC--Enveloppe convexe : sélection de modèles

Question: Parmi un ensemble de modèles candidats, comment éliminer d'office ceux qui ne seront pas intéressants ?

- ▶ **Enveloppe convexe:** est formée par les courbes qui, à un moment ou à un autre, n'ont aucune courbe « au-dessus » d'elles.
- ▶ Les courbes situées sur cette enveloppe correspondent aux modèles qui sont potentiellement les plus performantes pour une matrice de coût donnée.
- ▶ Les modèles qui ne participent jamais à cette enveloppe peuvent être éliminés




Interprétation:

- l'enveloppe convexe est formée par les courbes de M3 et M2.
- M1 est dominé par tous les modèles → il peut être éliminé
- M4 peut être meilleur que M3 dans certains cas, mais dans ces cas là, il sera moins bon que M2 → M4 peut être éliminé.

Courbe précision-rappel

- La courbe précision-rappel vient souvent compléter la courbe ROC.
- On appelle courbe précision-rappel, ou Precision-Recall curve en anglais, la courbe décrivant l'évolution de la **précision** en fonction du **rappel**, lorsque le seuil de décision change.



Conclusion-ROC

- ▶ Dans de nombreuses applications, la courbe ROC fournit des informations plus intéressantes sur la qualité de l'apprentissage que le simple taux d'erreur.
 - + C'est surtout vrai lorsque les classes sont très déséquilibrées, et lorsque le coût de mauvaise affectation est susceptible de modifications.
 - Il faut néanmoins que l'on ait une classe cible (positive) clairement identifiée et que la méthode d'apprentissage puisse fournir un SCORE proportionnel à $P(Y=+|X)$.

Erreurs de régression

- Dans le cas d'un problème de régression, le nombre d'erreurs n'est pas un critère approprié pour évaluer la performance.
- D'une part, à cause des imprécisions numériques, il est délicat de dire d'une prédiction à valeur réelle si elle est correcte ou non.

Question: quel est le meilleur modèle M1 ou M2?

- ▶ M1: Un modèle dont 50% des prédictions sont correctes à 0.1% près et les 50% autres sont très éloignées des vraies valeurs!
- ▶ M2: Un modèle modèl qui n'est correct qu'à 1% près, mais pour 100% des exemples ?

Solution: quantifier la performance d'un modèle de régression en fonction de l'écart entre les prédictions et les valeurs réelles.

Erreurs de régression

(**Erreur quadratique moyenne (MSE)**) Étant données n étiquettes réelles y^1, y^2, \dots, y^n et n prédictions $f(\vec{x}^1), f(\vec{x}^2), \dots, f(\vec{x}^n)$, on appelle *erreur quadratique moyenne*, ou *MSE* de l'anglais *mean squared error* la valeur

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (f(\vec{x}^i) - y^i)^2.$$

- Pour mesurer l'erreur **dans la même unité** que la cible, on lui préfère souvent sa **racine**:

(**RMSE**) Étant données n étiquettes réelles y^1, y^2, \dots, y^n et n prédictions $f(\vec{x}^1), f(\vec{x}^2), \dots, f(\vec{x}^n)$, on appelle *racine de l'erreur quadratique moyenne*, ou *RMSE* de l'anglais *root mean squared error* la valeur

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (f(\vec{x}^i) - y^i)^2}.$$

- Dans le cas où les valeurs cibles couvrent **plusieurs ordres de grandeur**, on préfère parfois passer au **log** avant de comparer les prédictions aux vals réelles , afin de ne pas donner plus d'importance aux erreurs faites pour des valeurs plus élevées.


(**RMSLE**) Étant données n étiquettes réelles y^1, y^2, \dots, y^n et n prédictions $f(\vec{x}^1), f(\vec{x}^2), \dots, f(\vec{x}^n)$, on appelle *racine du log de l'erreur quadratique moyenne*, ou *RMSLE* de l'anglais *root mean squared log error* la valeur

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(f(\vec{x}^i) + 1) - \log(y^i + 1))^2}.$$

Erreurs de régression--Normalisation

- L'interprétation de ces erreurs requiert néanmoins de connaître la distribution des valeurs cibles;
 - une RMSE de 1 cm n'aura pas la même signification selon qu'on essaie de prédire la taille d'humains ou celle de drosophiles (insecte).
- Pour répondre à cela, il est possible de normaliser la somme des carrés des résidus non pas en en faisant la moyenne, mais en la comparant à la somme des distances des valeurs cibles à leur moyenne.


Ensembles de données (collections)



Généralisation et sur-apprentissage et l'ensembles de données

- **Généralisation:** c'est la capacité d'un modèle à faire des prédictions correctes sur de nouvelles données, qui n'ont pas été utilisées pour le construire.
- **Sur-apprentissage ou overfitting :** un modèle qui, plutôt que de capturer la nature des objets à étiqueter, modélise aussi le bruit et ne sera pas en mesure de généraliser qu'il sur-apprend.
- **Sous-apprentissage ou underfitting:** un modèle qui est trop simple pour avoir de bonnes performances même sur les données utilisées pour le construire qu'il sous-apprend.


Généralisation et sur-apprentissage et l'ensembles de données—Interprétation Exemple 1



Pour séparer les observations négatives (x) des observations positives (+), la droite pointillée sousapprend.

- La frontière de séparation en trait plein (rouge) ne fait aucune erreur sur les données mais est susceptible de sur-apprendre.
- La frontière de séparation en trait discontinu est un bon compromis.

Généralisation et sur-apprentissage et l'ensembles de données—Interprétation Exemple2



Les étiquettes y des observations (représentées par des points) ont été générées à partir d'un polynôme de degré $d = 3$.
→ Le modèle de degré $d = 2$ approxime très mal les données et **sous-apprend**, tandis que celui de degré $d = 13$, dont le risque empirique est plus faible, **surapprend**.

Points clefs

- Pour éviter le sur-apprentissage, il est essentiel lors de l'étape de sélection du modèle de valider les différents modèles testés sur un jeu de données différent de celui utilisé pour l'entraînement.
- Pour estimer la performance en généralisation d'un modèle, il est essentiel de l'évaluer sur des données qui n'ont été utilisées ni pour l'entraînement, ni pour la sélection de ce modèle.
- De nombreux critères permettent d'évaluer la performance prédictive d'un modèle. On les choisira en fonction de l'application.
- Pour interpréter la performance d'un modèle, il peut être utile de le comparer à une approche naïve.

Exemple

- Soit l'exemple d'un test clinique
- Il ne s'agit pas ici d'un modèle d'apprentissage automatique, mais d'un frottis de dépistage du cancer du col de l'utérus : il s'agit d'un examen beaucoup plus simple et moins invasif qu'un examen histologique, qui doit être interprété par un expert, et servira de vérité terrain.
- Les résultats d'une expérience menée sur 4 000 femmes âgées de 40 ans et plus sont présentés sur le tableau.

	Cancer	Pas de cancer	Total
Frottis +	190	210	400
Frottis -	10	3590	3600
Total	200	3800	4000

Interprétation

Le **rappel** est de **95%**, la **spécificité** de **94.5%**, mais la **précision** ne vaut que **47.5%**.

- Ce test est un bon outil de dépistage : la probabilité de n'avoir effectivement pas de cancer quand le frottis est négatif est élevée ($3590/3600 \approx 99.7\%$).
- **MAIS, c'est un mauvais outil diagnostique**, au sens où la probabilité de fausse alarme

 ³³est très élevée!

Courbe ROC --Exemple


- ▶ Exemple de résultats d'une expérience de classification binaire, évaluée sur 6 échantillons.

Étiquette	+	-	+	+	-	-
Score	0.9	0.8	0.6	0.4	0.3	0.1

- Pour un seuil supérieur à 0.9, les 6 exemples sont étiquetés négatifs.
- On commence donc par le point (0, 0).
- Pour un seuil entre 0.95 et 0.9, seule la première observation est étiquetée positive.
- La sensibilité est donc de 1/3 tandis que l'antispécificité reste nulle.
- On peut continuer ainsi jusqu'à utiliser un seuil inférieur à 0.1 :

Seuil	> 0.9	0.8–0.9	0.6–0.8	0.4–0.6	0.3–0.4	0.1–0.3	< 0.1
TP/P	0	1/3	1/3	2/3	1	1	1
FP/P	0	0	1/3	1/3	1/3	2/3	1

Courbe ROC -Exemple (suite)



Courbe précision-rappel--Exemple

Étiquette	+	-	+	+	-	-
Score	0.9	0.8	0.6	0.4	0.3	0.1

- ▶ Les valeurs de la précision et du rappel sont les suivantes:

Seuil	> 0.9	0.8–0.9	0.6–0.8	0.4–0.6	0.3–0.4	0.1–0.3	< 0.1
Rappel	0	1/3	1/3	2/3	1	1	1
Précision	-	1	1/2	2/3	3/4	3/5	3/6

On obtient donc la courbe précision-rappel

